Tecnológico de Monterrey

Campus Puebla

Analítica de datos y herramientas de inteligencia artificial (Gpo 601)

Actividad 5 (Evaluación)

Reporte de hallazgos: regresión lineal simple, múltiple y logística

Iker Reyes

A01658664

Profesor: Alfredo García

19 de octubre de 2026

1. Principales hallazgos

Se analizó la base de inventario *Datos_Complementarios_CLV.xlsx* (2,951 artículos) para entender qué explica el valor del inventario de cada artículo y qué tan bien se puede identificar a los artículos de alto valor. Los hallazgos más relevantes son:

- **La marca es casi tan importante como la cantidad.** Las existencias por sí solas explican el 36.8 % de la variación del valor del inventario; al agregar la marca, el modelo explica el **64.2 %**. Saber de qué marca es un artículo mejora en 27 puntos la capacidad de predecir su valor.
- **El valor crece un poco menos que proporcionalmente a las existencias.** Un aumento de 1 % en existencias se asocia con un aumento de 0.87 % en el valor: los artículos que se tienen en mayor cantidad tienden a ser de menor costo unitario.
- **Al comparar artículos de la misma marca, el efecto de las existencias es mayor**: la elasticidad sube de 0.87 a **0.96** en el modelo múltiple, es decir, dentro de cada marca el valor responde casi 1 a 1 a la cantidad.
- **Hay marcas asociadas a inventario de alto valor y otras a bajo valor.** 20 de las 26 marcas tienen un efecto significativo. Amann Girrbach, Exocad y Aidite aumentan la probabilidad de que un artículo sea de alto valor; Huge y Vita la reducen. Vita concentra la mayoría de los artículos de la base, pero de valor individual bajo.
- **Tener existencias por encima de la mediana multiplica por 10.6 los momios** de que el artículo esté en el 25 % de mayor valor; es la única variable dicotómica significativa.
- **Balancear las clases mejora la detección de artículos de alto valor**: el modelo sin balanceo identifica al 63 % de ellos; con reponderación de clases u oversampling se detecta a más del **81 %** (AUC = 0.908).

2. Base de datos y preprocesamiento

La base original contiene 2,951 registros con las columnas *articulo, nombre_articulo, marca, almacen, existencias* y *valor_inventario*. Se realizaron las siguientes acciones:

- **Nulos:** no se encontraron valores faltantes en ninguna columna, por lo que no fue necesario imputar.
- **Duplicados:** se revisaron antes de quitar las claves de producto; no había registros duplicados, por lo que se conservaron los 2,951 artículos.
- **Columnas excluidas:** *articulo* y *nombre_articulo* son claves de producto (aunque una sea numérica, no representa una cantidad) y *almacen* tiene un solo valor ("Almacén General"), así que no aporta información.
- **Transformaciones:** existencias y valor del inventario tenían una asimetría muy fuerte (pocos artículos con valores muy altos), por lo que se transformaron con log(1 + x). La marca (26 categorías) se convirtió a variables dummy.

- **Outliers:** después del logaritmo, los valores atípicos restantes se identificaron con el método IQR y se acotaron a sus límites, sin eliminar registros.

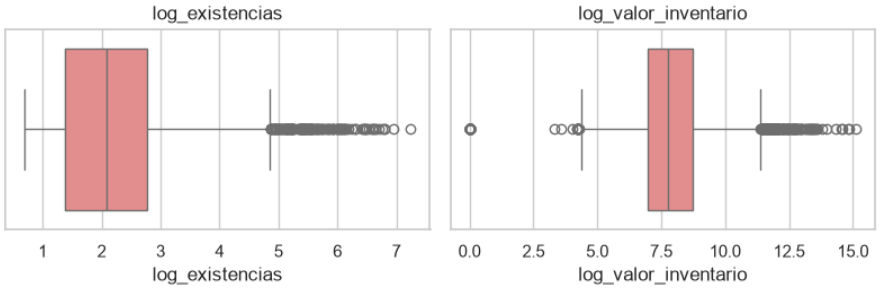


Figura 1. Boxplots antes de tratar los outliers (en escala logarítmica).

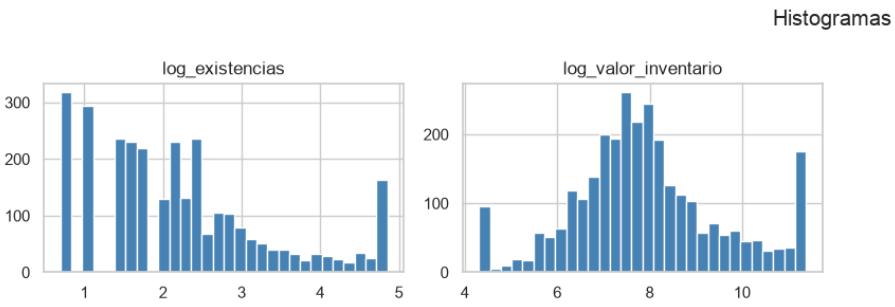


Figura 2. Distribución final de las variables transformadas.

3. Regresión lineal simple

La correlación más alta de la base es entre **log_existencias** y **log_valor_inventario** (r = 0.607, correlación fuerte y positiva). Con ellas se obtuvo el modelo:

log(valor_inventario) = 5.9981 + 0.8677 · log(existencias)

Indicador	Valor
Correlación (r)	0.6069
R cuadrado (R2)	0.3684
Intercepto (b0)	5.9981
Pendiente (b1)	0.8677

Interpretación. Como ambas variables están en logaritmo, la pendiente es una elasticidad: si las existencias de un artículo aumentan 1 %, su valor de inventario aumenta en promedio 0.87 %. Las existencias explican poco más de un tercio de la variación del valor, por lo que hay otros factores importantes.

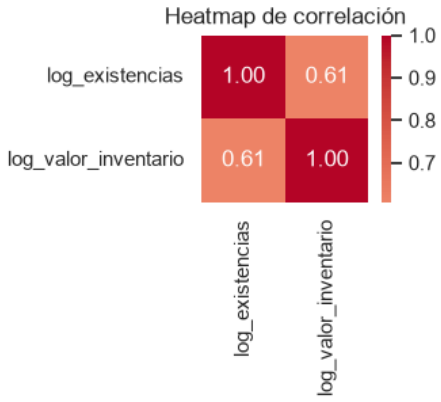


Figura 3. Matriz de correlación.

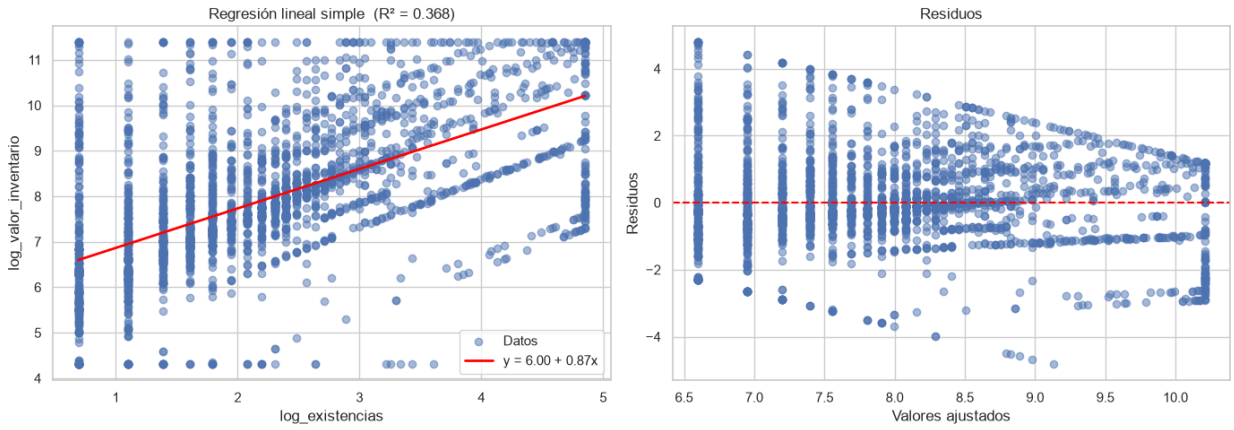


Figura 4. Recta de regresión lineal simple y gráfica de residuos.

4. Regresión lineal múltiple

Se partió de las existencias y las 26 marcas (como dummies), se revisó la multicolinealidad (VIF > 10) y se eliminaron una a una las variables no significativas (p > 0.05). El mejor modelo conserva **21 predictores**: log_existencias y 20 marcas.

Concepto	Modelo simple	Modelo múltiple
Coeficiente de log_existencias	0.8677	0.9620
Número de predictores	1	21
R cuadrado ajustado	0.3682	0.6419

Comparación de coeficientes. El coeficiente de log_existencias aumentó 10.9 % (de 0.8677 a 0.9620). En el modelo simple, el efecto de la cantidad se mezclaba con el de la marca: las marcas con muchas unidades en inventario suelen ser de bajo costo, lo que "aplanaba" la pendiente. Al comparar artículos de la misma marca, el valor responde casi proporcionalmente a las existencias.

Mejora del ajuste. El R^2 ajustado pasa de 0.368 a 0.642 (+0.274). La marca explica buena parte de la variación que el modelo simple no podía explicar, por lo que es una variable clave para estimar el valor del inventario.

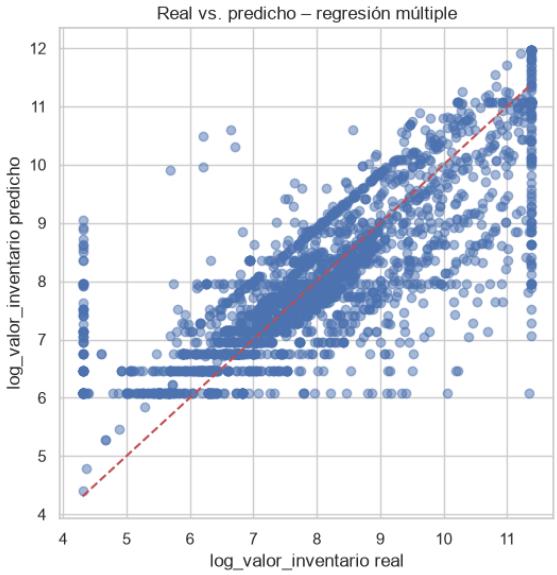


Figura 5. Valores reales contra predichos del modelo múltiple.

5. Regresión logística con reponderación de clases y oversampling

Como la base no tiene una variable sí/no, se creó **valor_inventario_alto** = 1 cuando el artículo está en el 25 % de mayor valor. Para evitar que el modelo "haga trampa", el valor del inventario se excluyó de los predictores; se usaron solo las existencias y la marca. Como la clase 1 es minoritaria (25 %), se compararon tres enfoques: modelo base, reponderación de clases y oversampling.

Modelo	Accuracy	Precisión (1)	Recall (1)	F1 (1)
Base (sin balanceo)	0.874	0.824	0.632	0.716
Reponderación de clases	**0.847**	**0.658**	**0.811**	**0.726**
Oversampling	0.844	0.650	0.822	0.726

El modelo base tiene el accuracy más alto (0.874), pero deja sin detectar a 68 de los 185 artículos de alto valor del conjunto de prueba (738 artículos). Las dos técnicas de balanceo suben el recall a más del 81 %: la **reponderación de clases** detecta 150 y el **oversampling** 152, con el mismo F1 (0.726). Se eligió la reponderación como mejor modelo (AUC = 0.908) porque genera un poco menos de falsas alarmas (78 contra 82). Esto confirma que, con clases desbalanceadas, el accuracy no es suficiente para evaluar un modelo.

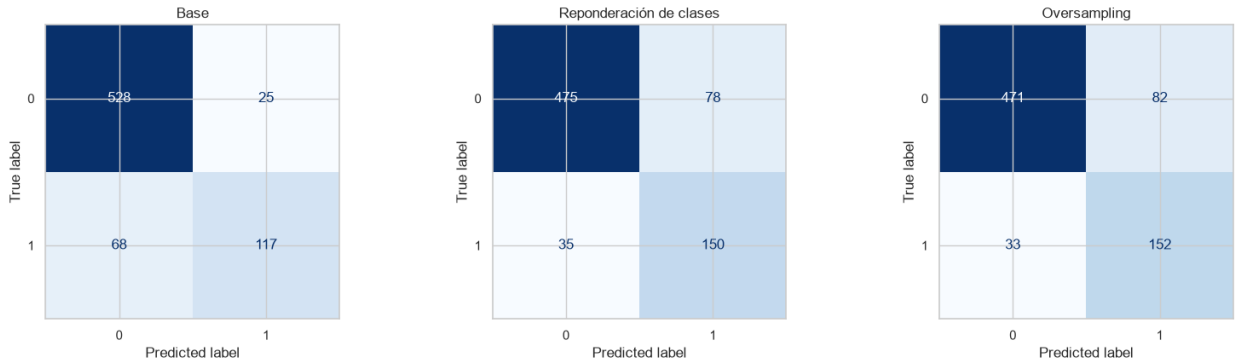


Figura 6. Matrices de confusión de los tres modelos.

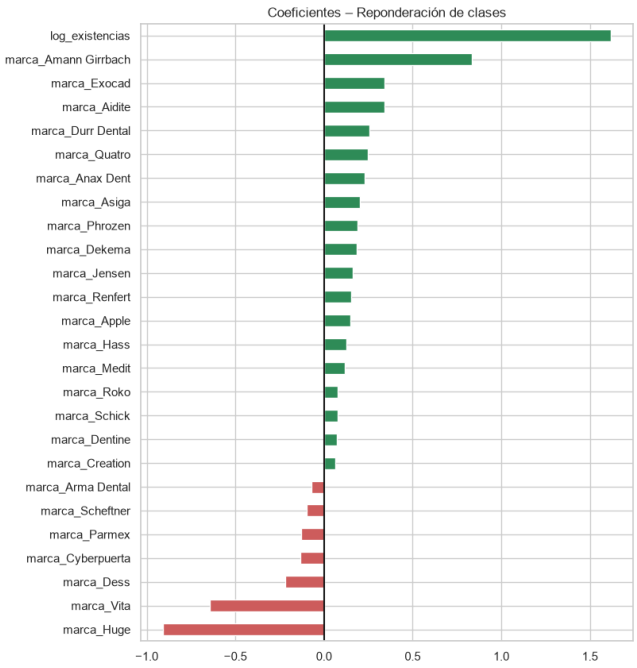


Figura 7. Coeficientes del mejor modelo (variables estandarizadas).

6. Regresión logística con variables dicotómicas

Se convirtieron las variables a 0/1: las existencias a *log_existencias_alto* (1 = por encima de la mediana) y la marca a una columna 0/1 por cada marca. Con ellas se ajustó la regresión logística, compensando el desbalance con pesos por clase.

Indicador	Valor
Odds ratio de log_existencias_alto	10.60
AUC	0.891
Accuracy	0.861
Recall (alto valor)	0.732
Precisión (alto valor)	0.717

> **Interpretación.** Un artículo con existencias por encima de la mediana tiene **10.6 veces** más momios de pertenecer al grupo de alto valor que uno con existencias bajas. Ninguna marca individual resultó significativa en esta versión, lo que indica que la cantidad en inventario es la señal más clara para identificar artículos de alto valor.

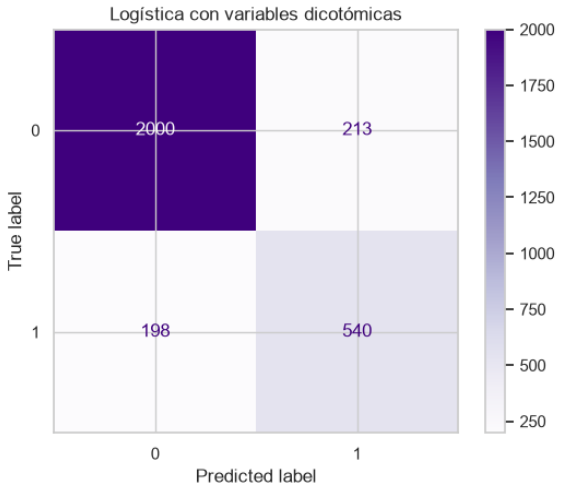


Figura 8. Matriz de confusión de la logística con variables dicotómicas.

7. Conclusiones

Preprocesamiento. La base quedó con 2,951 registros y 3 variables después de la limpieza. Se revisaron valores nulos (imputando con mediana o moda cuando existían), se acotaron los outliers con el método IQR y se convirtieron las variables categóricas a dummies para poder usarlas en los modelos. Se eliminaron columnas que eran códigos o constantes (articulo, nombre_articulo, almacen). Las variables existencias y valor_inventario tenían una asimetría fuerte, por lo que se transformaron con log(1+x).

Correlación. El par de variables con mayor correlación fue log_existencias y log_valor_inventario, con r = 0.6069, una correlación fuerte y positiva: cuando log_existencias aumenta, log_valor_inventario tiende a aumentar.

Regresión lineal simple. El modelo obtenido es log_valor_inventario = 5.9981 + (0.8677)·log_existencias, con R^2 = 0.3684, es decir, log_existencias explica el 36.8 % de la variación de log_valor_inventario. Como ambas variables están en logaritmo, b1 es una elasticidad: si existencias aumenta 1 %, valor_inventario aumenta aproximadamente 0.8677 %.

Regresión lineal múltiple. Tras eliminar variables con multicolinealidad (VIF > 10) y no significativas (p > 0.05), el mejor modelo usa 21 predictores (log_existencias, marca_Aidite, marca_Amann Girrbach, marca_Anax Dent, marca_Apple, marca_Arma Dental, marca_Asiga, marca_Creation, marca_Cyberpuerta, marca_Dekema, marca_Dentine, marca_Durr Dental, marca_Exocad, marca_Hass, marca_Huge, marca_Jensen, marca_Medit, marca_Phrozen, marca_Quatro, marca_Renfert, marca_Roko) y alcanza un R^2 ajustado = 0.6419, frente a 0.3682 del modelo simple (mejora de +0.2738). El coeficiente de log_existencias pasó de 0.8677 en el modelo simple a 0.9620 en el múltiple (+10.9 %). La diferencia se debe a que en el modelo múltiple el efecto de log_existencias se mide controlando por las demás variables, por lo que parte de la relación que el modelo simple le atribuía se explica ahora por otros predictores.

Regresión logística con balanceo. Se usó la variable dicotómica valor_inventario_alto, cuya clase minoritaria representa solo el 25.0 % de los datos. El modelo base obtuvo un accuracy de 0.874 pero un recall de 0.632 en la clase minoritaria, lo que muestra que el accuracy engaña con clases desbalanceadas. La mejor técnica fue Reponderación de clases, con recall = 0.811, F1 = 0.726 y AUC = 0.908.

Regresión logística con variables dicotómicas. Al convertir las variables a 0/1 (alto/bajo por mediana y dummies), la variable significativa fue log_existencias_alto (aumenta los momios, OR = 10.60). El modelo alcanzó un AUC = 0.891.

8. Recomendaciones

- Considerar la marca, y no solo la cantidad, al estimar o auditar el valor del inventario: incluirla eleva la capacidad explicativa del 37 % al 64 %.
- Dar seguimiento especial a las marcas asociadas a alto valor (Amann Girrbach, Exocad, Aidite), donde un error de conteo tiene mayor impacto económico.
- Priorizar el control y conteo de los artículos con existencias altas, ya que tienen 10.6 veces más momios de estar entre los de mayor valor.
- Agregar a la base variables como costo unitario, categoría del producto o fecha de última venta, que permitirían explicar mejor el valor y detectar inventario de lento movimiento.